Sequenciação de Nova Geração

- Sequenciação do DNA
- NGS: formatos de ficheiro
- NGS: controlo de qualidade e pré-processamento de fastQ
- NGS: alinhamento de sequências

※ 〇

1

Genoma Humano



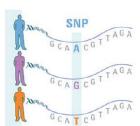
- Todos os seres humanos são semelhantes ao nível do DNA, sendo que mais de 99% do material genético é igual entre diferentes pessoas.
- Os restantes 1% são muito importantes, visto serem a fração que nos diferencia entre si:
 - o Determinam a cor dos nossos olhos, cabelo ou pele;
 - Também influenciam o risco de contrair uma determinada doença ou a resposta a um tratamento com um fármaco.

※ 〇

Laboratórios de Bioinformática

Polimorfismo de nucleotídeo único

- Polimorfismo de nucleotídeo único ou SNP é uma variação de nucleótido que ocorre numa única posição da sequencia de DNA entre vários indivíduos.
- Se um SNP ocorrer dentro de um gene, então o gene é descrito como tendo mais que um alelo.
- Alguns SNP estão associados a determinadas doenças, por essa razão, avaliações genéticas que detetam a predisposição de doenças em determinados pacientes são efetuadas com o recurso de identificação de SNPs.



☆ 〇

Laboratórios de Bioinformática

3

Tipos de alterações SNP

Single nucleotide changes
A schematic illustration of
(I) single nucleotide polymorphism or
or single nucleotide substitution
(II) single nucleotide insertion
(III) single nucleotide deletion



Single nucleotide substitution of G>A CCG TA(A)CAA GGA

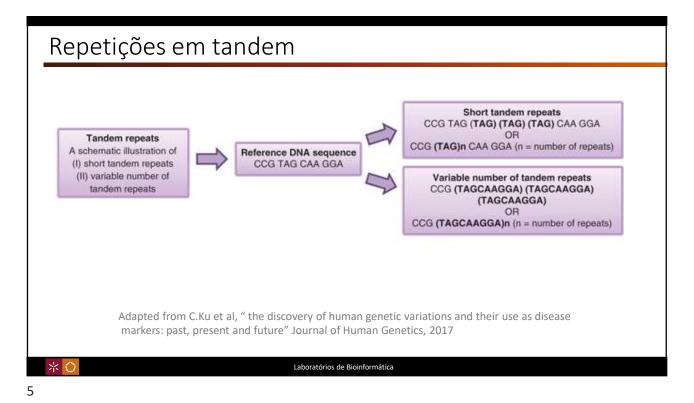
Single nucleotide insertion of T CCG TAG(T)CAA GGA

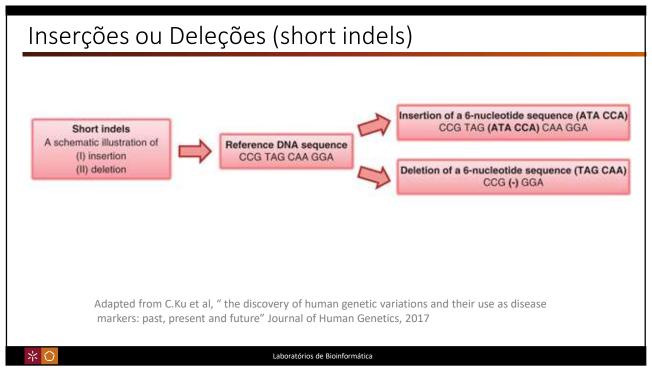
Single nucleotide deletion of G CCG TA(-)CAA GGA

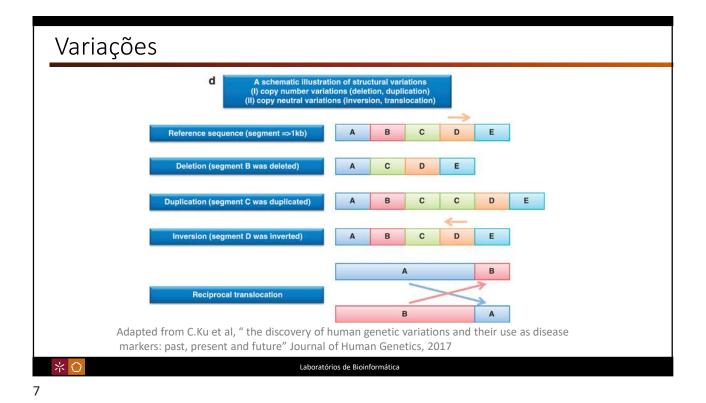
Adapted from C.Ku et al, "the discovery of human genetic variations and their use as disease markers: past, present and future" Journal of Human Genetics, 2017

☆ ○

Laboratórios de Bioinformática



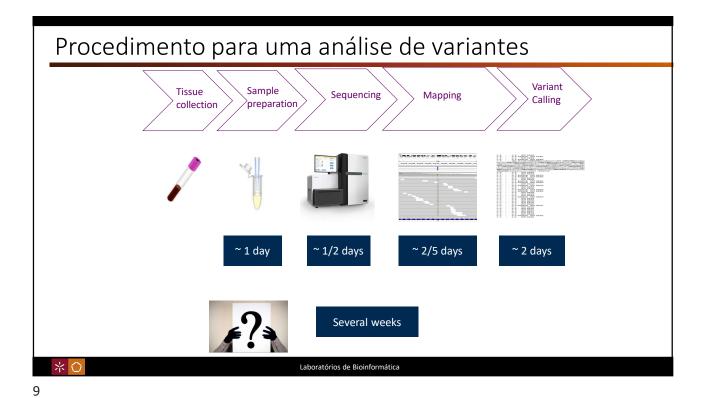




Sequenciação do DNA

- As aplicações dos sequenciadores de nova geração para o DNA incluem:
 - o Assemblagem de um novo genoma;
 - o Descoberta de variações de nucleótidos únicos;
 - o Deteção de variações de números de cópia de DNA;
 - o Deteção de rearranjos estruturais no DNA.

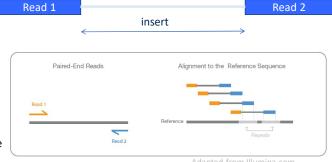
* ①



Preparação das amostras com primers Forward Primer Amplicon PCR Genomic DNA sequenciadores Os requerem Region of interest CO1 or 18S primers que permitem a iniciação do PCR bem como a identificação AMPure XP bead purification Index PCR using Illumina Nextera XT Library Preparation Kit sequências obtidas das das Overlapping region amostras. O existem diversas bibliotecas de AMPure XP bead purification preparação com primers (por exemplo o Illumina Nextera XT kit ou o Illumina TruSeq PE V3 kit) Quantification, Normalization, Pooling Sequencing (Illumina MiSeq) Laboratórios de Bioinformática

Reads de sequências (conceitos)

- Insert O fragmento de DNA utilizado para a sequenciação.
- Read A secção do insert que foi sequenciada
- Single Read (SR) Um procedimento de sequenciação no qual o insert é sequenciado somente num sentido.
- Paired End (PE) Um procedimento de sequenciação no qual o insert é sequenciado em ambos os sentidos (a quantidade de sequencias lidas a tratar será sempre o dobro).
- Insert size A distância média em nucleótidos entre os pares de reads



11

NGS: formatos de ficheiro

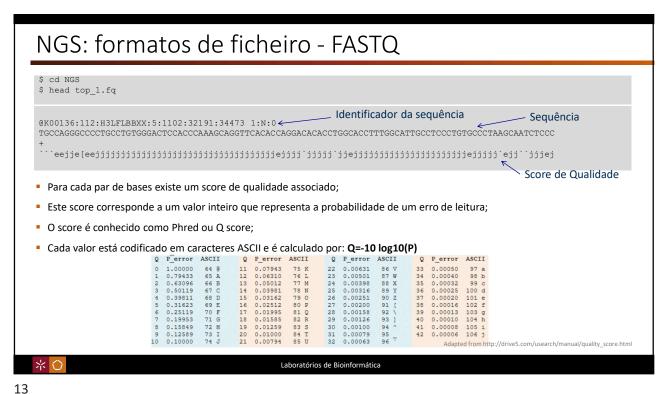
- Equipamento de NGS pode exportar dados nos seguintes formatos: FASTA, FASTQ, SAM/BAM
- Além destes, também existem formatos comuns utilizados na deteção das variações mencionadas anteriormente:

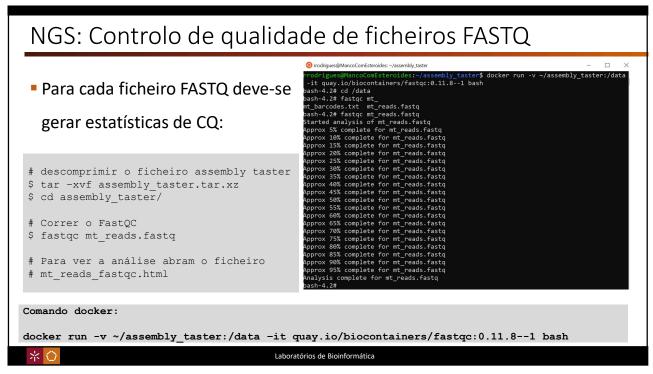
BED, GFF, GTP, VCF

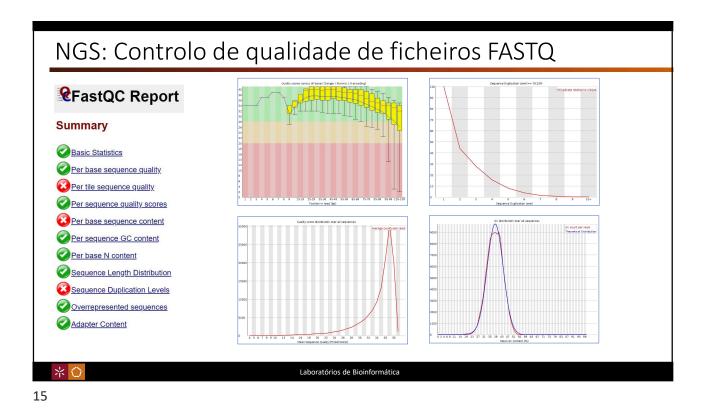
Ficheiro zip com os datasets dos slides:

https://nextcloud.bio.di.uminho.pt/s/C46mZjoE3oStqsT

※ 〇







Por vezes as reads do ficheiro FASTQ contêm os primers de sequenciação e necessitam de ser removidos. Para este processo existe softwares como o trimmomatic, fastxtools, cutadapt, bbduk, sickle, etc. Para este processo existe softwares como o trimmomatic, fastxtools, cutadapt, bbduk, sickle, etc.

NGS: Pré-processamento de ficheiros FASTQ

```
teroides:~/assembly_taster$ docker run --rm -v ~/assembly_taster:/data
 -it quay.io/biocontainers/trimmomatic:0.35--6 bash
bash-4.2# cd /data
bash-4.2# 1s
README.txt
                                                                                 O Trimmomatic
glimmer_to_gbk.perl
gilmmen_to_gok.perl mt_read
numan_mitochondrial.gbk top.bam
                                                                             disponibiliza as sequências
                                                                            dos primers mais utilizados!
bash-4.2# ls /usr/local/share/trimmomatic-0.35-6/adapters
                                                                             Estes ficheiros podem ser
NexteraPE-PE.fa TruSeq2-SE.fa TruSeq3-PE.fa
                                                                            utilizados no parâmetro do
TruSeq2-PE.fa TruSeq3-PE-2.fa TruSeq3-SE.fa
                                                                                  ILLUMINACLIP
bash-4.2#
```

Comando docker:

docker run --rm -v ~/assembly taster:/data -it quay.io/biocontainers/trimmomatic:0.35--6 bash

- http://www.usadellab.org/cms/uploads/supplementary/Trimmomatic/TrimmomaticManual V0.32.pdf
- https://thesequencingcenter.com/knowledge-base/trimming-illumina-adapter-sequences/



Laboratórios de Bioinformática

17

NGS: Pré-processamento de ficheiros FASTQ

Exemplo commando Trimmomatic para SE:

trimmomatic SE -phred33 input.fq.gz output.fq.gz ILLUMINACLIP:/usr/local/share/trimmomatic-0.35-6/adapters/TruSeq3-SE:2:30:10 LEADING:3 TRAILING:3 SLIDINGWINDOW:4:15 MINLEN:36 AVGQUAL:28

Exemplo commando Trimmomatic para PE:

trimmomatic PE input_forward.fq.gz input_reverse.fq.gz output_forward_paired.fq.gz output_forward_unpaired.fq.gz output_reverse_paired.fq.gz output_reverse_unpaired.fq.gz ILLUMINACLIP:/usr/local/share/trimmomatic-0.35-6/adapters/TruSeq3-PE.fa:2:30:10 LEADING:3 TRAILING:3 MINLEN:36 AVGQUAL:28



NGS: Alinhamento de sequencias – SAM/BAM

- SAM/BAM (.sam, .bam) é abreviação para sequence alignment map. Este formato de ficheiro contem colunas separadas por tabs, no qual detalha informação de reads contra um genoma/sequência de referencia.
 - SAM apresenta os dados em formato de texto, enquanto que o BAM é a versão binária com otimização para executar indexação.
- O cabeçalho destes ficheiros começa com um símbolo '@'.
- Cada coluna consiste em:

Discrição detalhada de cada coluna em: http://bioinformatics.cvr.ac.uk/blog/java-cigarparser-for-sam-format/ Format:

1. QNAME Query template/pair NAME
2. FLAG bitwise FLAG
3. RNAME Reference sequence NAME
4. POS 1-based leftmost POSition/coordinate of clipped sequence
5. MAPQ MAPping Quality (Phred-scaled)
6. CIGAR extended CIGAR string
7. MRNM Mate Reference sequence NaMe ('=' if same as RNAME)
8. MPOS 1-based Mate POSistion
9. LEN inferred Template LENgth (insert size)
10. SEQ query SEQuence on the same strand as the reference
11. QUAL query QUALity (ASCII-33 gives the Phred base quality)

12. OPT variable OPTional fields in the format TAG:VTYPE:VALUE



Laboratórios de Bioinformática

19

NGS: Alinhamento de sequências - SAM/BAM

Samtools é um pacote de ferramentas para a manipulação de ficheiros SAM e BAM.

```
The EDIX View Cauch Terminal Heigh

**Actionary accessible Terminate Control Terminal Heigh

**Actionary accessible Terminate Control Terminal Height

**Bottom Community**

**Companies**

- IndexIng

- Commands:

- IndexIng

- IndexIng

- Commands:

- Commands:

- IndexIng

- Commands:

- Commands:

- IndexIng

- Commands:

- Com
```

```
Bioinformatics linux contains samtools docker:
docker run -it biocontainers/samtools:v1.7.0_cv4 bash

Usage: samtools <command> [options]
```

```
Command: view
                         SAM<->BAM conversion
                         sort alignment file
multi-way pileup
compute the depth
index/extract FASTA
          sort
          mpileup
          depth
faidx
          tview
index
                         text alignment viewer
                         index alignment
          idxstats
                         BAM index stats (r595 or later)
          fixmate
                         fix mate information
          flagstat
                         simple stats
                         recalculate MD/NM tags and '=' bases
          calmd
                         merge sorted alignments
          merge
                         remove PCR duplicates replace BAM header
          {\tt rmdup}
          reheader
                         concatenate BAMs
          bedcov
                         read depth per BED region
          targetcut
                         cut fosmid regions (for fosmid pool only)
                         phase heterozygotes shuffle and group alignments by name
           phase
           bamshuf
```

NGS: Alinhamento de sequências – SAM/BAM

Conversão de um ficheiro SAM para BAM pode ser efetuada com:

```
swget
http://hgdownload.cse.ucsc.edu/goldenPath/hg19/encodeDCC/wgEncodeUwRepliSeq/wgEncodeUwRe
pliSeqBg02esG1bAlnRepl.bam

$ samtools view -h wgEncodeUwRepliSeqBg02esG1bAlnRepl.bam | head -1000 > top.sam

$ samtools view -b top.sam > top.bam

biodocker@oeb01oes6b8t/dats wget http://hgdownload.cse.ucsc.edu/goldenPath/hg19/encodeDcC/wgEncodeUwRepliSeqBg02esG1bAlnRepl.ban
-2019-18-21 17:113-4- http://hgdownload.cse.ucsc.edu/goldenPath/hg19/encodeUcRepliSeqBg02esG1bAlnRepl.ban
-2019-18-21 17:113-4- http://hgdownload.cse.ucsc.edu/goldenPath/hg19/encodeUcRepliSeqBg02esG1bAlnRepl.ban
-2019-18-21 17:113-4- http://hgdownload.cse.ucsc.edu/goldenPath/hg19/encodeUwRepliSeqBg02esG1bAlnRepl.ban
-2019-18-21 17:113-14- http://hgdownload.cse.ucsc.edu/goldenPath/hg19/en
```

Laboratórios de Bioinformática

21

NGS: Mapear reads para o genoma (chr21)

- Neste caso de estudo pretende-se utilizar um dataset de reads (HG00154.chr21) do projeto 1000 Genomes.
- Para efetuar o alinhamento dos reads deve-se criar um índex com o algoritmo Burrows-Wheeler transform para a sequencia de referência.
- Posteriormente, deve-se gerar as coordenadas genómicas para todos os reads (ficheiro .sai).

```
Comando docker:
docker run -it biocontainers/bwa:v0.7.17-3-deb_cv1 bash

# Build an index for the sequence of chr 21
$ bwa index 21.fa

# align reads to reference sequence, getting genomic coordinates
$ bwa aln 21.fa HG00154.chr21.fastq.gz > HG00154.chr21.sai
```

```
File Edit View Search Fremioni Help

thotofromaticallycolorinomatica-VirtualBos:-/Besktop5 ter -xvf dna.ter.gz
dna/
dna/21.fg
```

NGS: Gerar o ficheiro BAM com alinhamentos

```
# Criar o ficheiro sam a partir dos reads
mapeados

$ bwa samse -f HG00154.chr21.aln.sam 21.fa
HG00154.chr21.sai HG00154.chr21.aln.sam 21.fa
HG00154.chr21.sai HG00154.chr21.fastq.gz
# Converter o sam em bam

$ samtools view -Sb HG00154.chr21.aln.sam

HG00154.chr21.aln.bam

HG00154.chr21.aln.bam

HG00154.chr21.aln.bam

HG00154.chr21.aln.bam

HG00154.chr21.aln.bam

HG00154.chr21.aln.bam

File Edit View Search Terminal Help

rootge624140785ee:/data# bwa samse -f HG00154.chr21.aln.sam 21.fa
HG00154.chr21.sai HG00154.chr21.ast HG00154.chr21.ast HG00154.chr21.ast HG00154.chr21.ast HG00154.chr21.ast HG00154.chr21.ast HG00154.chr21.ast HG00154.chr21.ast HG00154.chr21.aln.sam

File Edit View Search Terminal Help

rootge624140785ee:/data# bwa samse -f HG00154.chr21.aln.sam 21.fa
HG00154.chr21.ast HG00154.chr21.ast HG00154.chr21.aln.sam

PG00154.chr21.aln.bam

HG00154.chr21.aln.bam

File Edit View Search Terminal Help

rootge624140785ee:/data# bwa samse -f HG00154.chr21.aln.sam 21.fa
HG00154.chr21.ast HG00154.chr21.ast HG00154.chr21.aln.sam

PG00154.chr21.ast HG00154.chr21.ast HG00154.chr21.aln.sam

PG00166.chr21.ast HG00154.chr21.ast HG00154.chr21.aln.sam

PG00167.4487c2505/data# Sequences have been processed.

PG00167.4487c2505/data# Se
```

23

NGS: Ordenar os reads para gerar estatísticas

```
# Ordernar os reads por coordenadas genómicas
$ samtools sort HG00154.chr21.aln.bam -o HG00154.chr21.aln.sort.bam

# Criar um indice com o ficheiro bam
$ samtools index HG00154.chr21.aln.sort.bam

# Obter as estatísticas do alinhamento
$ samtools flagstat HG00154.chr21.aln.sort.bam

| File Edit View Search Terminal Help | root@6724487c2505: /data santools sort UC00154.chr21.aln.bam -o HC00154.chr21.aln.sort.bam | root@724487c2505: /data# santools sort UC00154.chr21.aln.sort.bam | root@724487c2505: /data# santools flagstat HC00154.chr21.aln.sort.bam | root@724487c2505: /data# santools flagstat HC00154.chr21.aln.sort.bam | root@72487c2505: /data# santools flagstat HC00154.chr21.aln.sort.bam
```